Statistik Projekt

Statistische Untersuchung der Preisdeterminanten
im Diamonds-Datensatz

Datum: 18. Februar 2026

Datum: 18. Februar 2026

Teilnehmer: Michael Werfring, Julia Tuka, Clemens Hafenscher

Inhaltsverzeichnis

1 Einleitung **1**

2 Kernanforderungen der Aufgabenstellung **2**

3 Ergebnisse der statistischen Analyse **3**

3.1 Deskriptive Befunde 3
3.2 Induktive Statistik 3
3.2.1 Konfidenzintervalle 3
3.2.2 Test auf Normalverteilung 3
3.2.3 Gerichteter t-Test 4
3.3 Regressionsmodellierung und Evaluation 4
3.3.1 Modell 1: Metrischer Basisansatz 4
3.3.2 Modell 2: Erweitertes numerisches Modell 4
3.3.3 Modell 3: Vollständiges Prädiktionsmodell 5
3.3.4 Modell 4: Domänenspezifischer Fokus (4Cs) 5
3.4 Modellvergleich und Generalisierungsfähigkeit 5
3.5 Zusammenfassung und abschließendes Fazit 6

1 Einleitung

Gegenstand dieses Projekts ist die statistische Analyse des diamonds-Datensatzes [1], der als Referenzdatensatz im **R**-Paket ggplot2 zur Verfügung steht. Der Datensatz umfasst preisrelevante Merkmale von über 53.000 geschliffenen Diamanten und bietet durch eine Mischung aus metrischen Variablen, wie z.B. Gewicht in Karat und physische Abmessungen, sowie ordinal skalierten Merkmalen, wie z.B. Schliffgüte, Farbe und Reinheit, die Grundlage für unser Projekt.

Die methodische Umsetzung erfolgte primär unter Verwendung der Programmiersprache **R**. Für die explorative Datenanalyse und die Erstellung der grafischen Repräsentationen wurde das Framework ggplot2 eingesetzt.

2 Kernanforderungen der Aufgabenstellung

Die Projektvorgabe definiert gewisse Grundvoraussetzung für die Umsetzung des Projekts. Diese beginnen im Bereich des Datenmanagements mit der Partitionierung des Datensatzes in ein Trainings-, Validations- und Test-Set im Verhältnis von 60:20:20. In diesem Zuge erfolgt zudem die gezielte Handhabung fehlender Werte mittels Imputation (ersetzung fehlender Werte), sowie die Identifikation und Bereinigung von Ausreißern. Die Auswertung ist in zwei Teilbereiche gegliedert; eine statistische Analyse durch Tests und andere Statistische-Werkzeuge und eine deskriptive Aufbereitung durch Grafiken. Die verwendeten Tests umfassen T-Tests und F-Tests. Ebenso wurden vier lineare Modelle zur Vorhersage des Diamantenpreises spezifiziert, wo ein unterschiedlicher Ansatz bei der Merkmalsauswahl vorliegt. Diese sind der Naiver-, Metrischer-, Vollmodell- und Domänenbasierter Ansatz.

3 Ergebnisse der statistischen Analyse

3.1 Deskriptive Befunde

Die Analyse der zentralen Lagemaße im Trainingsdatensatz zeigt einen Durchschnittspreis von ca. 3.913 $ bei einem Median von 2.395 $. Diese Diskrepanz verdeutlicht die starke Rechtsschiefe der Preisverteilung: Während die Mehrheit der Diamanten im unteren Preissegment liegt, ziehen einige exklusive Exemplare den Mittelwert nach oben. Das durchschnittliche Gewicht beträgt ca. 0,80 Karat (in den Daten als Variable `carat` geführt). Die Korrelationsanalyse bestätigt, dass das Gewicht (`carat`) und die physischen Abmessungen (`x`, `y`, `z`) stark mit dem Preis korrelieren ($r > 0,88$).

3.2 Induktive Statistik

In diesem Abschnitt wird die Variable *depth* (relative Tiefe in %) untersucht. Die Analyse umfasst die Bestimmung von Konfidenzintervallen, Tests auf Normalverteilung sowie einen gerichteten t-Test zum Vergleich von Schliffqualitäten.

3.2.1 Konfidenzintervalle

Für die Variable *depth* wurde ein Konfidenzniveau von 95 % gewählt. Die Quantile ergeben folgendes Intervall für die Grundgesamtheit:

$$CI_{95\%} = [58,6\,\%; 64,4\,\%] \tag{1}$$

3.2.2 Test auf Normalverteilung

Zur Überprüfung der Normalverteilung der Variable *depth* wurde der Kolmogorov-Smirnov-Test (KS-Test) herangezogen. Die Hypothesen wurden wie folgt definiert:

- H_0: Die Variable *depth* folgt einer Normalverteilung.
- H_1: Die Variable *depth* folgt keiner Normalverteilung.

Die Testergebnisse für den ursprünglichen Datensatz sowie den gefilterten Datensatz (Ausschluss der extremen 2 %) lauten:

- **Originaldaten:** $D = 0,0759$, $p < 2,2 \cdot 10^{-16}$.
- **Gefilterte Daten:** $D = 0,0630$, $p < 2,2 \cdot 10^{-16}$.

Aufgrund der extrem kleinen p-Werte wird H_0 in beiden Fällen verworfen. Das deudet signifikant darauf hin, dass die Daten nicht normalverteilt sein.

3.2.3 Gerichteter t-Test

Es wurde untersucht, ob *cut* (Schliffqualität) einen Einfluss auf die Tiefe des Diamanten hat. Konkret wurde getestet, ob Diamanten mit der Qualität F̈airẗiefer geschnitten sind als jene mit der Qualität Ïdeal:

- $H_0 : \mu_{\text{Fair}} \leq \mu_{\text{Ideal}}$
- $H_1 : \mu_{\text{Fair}} > \mu_{\text{Ideal}}$

Die statistische Auswertung lieferte folgende Kennzahlen:

- $t \approx 25,65$ bei $df \approx 1618,36$ Freiheitsgraden.
- $p \approx 2,51 \cdot 10^{-122}$.
- Geschätzte Differenz (*estimate*): $2,33\,\%$.
- Untere Grenze des Konfidenzintervalls (*lower_ci*): $2,18\,\%$.

Da $p < \alpha$ $(0,05)$, wird H_0 verworfen. Mit einer Konfidenz von $95\,\%$ kann bestätigt werden, dass F̈airg̈eschnittene Diamanten im Mittel mindestens $2,18\,\%$ tiefer sind als Ïdealg̈eschnittene.

3.3 Regressionsmodellierung und Evaluation

In diesem Abschnitt werden die vier entwickelten Regressionsmodelle detailliert beschrieben und hinsichtlich ihrer prädiktiven Performance auf den Train-, Validations- und Testdatensätzen evaluiert.

3.3.1 Modell 1: Metrischer Basisansatz

Das erste Modell verfolgt einen naiven Ansatz und konzentriert sich auf Variablen mit der höchsten bivariaten Korrelation zum Preis. Als Prädiktoren dienen das Gewicht (`carat`) sowie die räumlichen Dimensionen (`x`, `y`, `z`). Trotz der hohen Korrelation der Einzelvariablen zeigt das Modell mit einem $RMSE$ von $1505,60$ im Training und $1518,87$ in der Validation eine vergleichsweise geringe Präzision. Auf dem Testset steigt der Fehler weiter auf einen $RMSE$ von $1704,63$ an.

3.3.2 Modell 2: Erweitertes numerisches Modell

Modell 2 erweitert den ersten Ansatz um die Kennzahlen `depth` (Gesamttiefe) und `table` (Tafelbreite). Ziel ist es zu überprüfen, ob zusätzliche geometrische Verhältnisse den Erklärungsgehalt signifikant steigern. Die Ergebnisse zeigen jedoch nur eine marginale Verbesserung der Fehlerwerte mit einem $RMSE$ von $1488,48$ im Training und $1489,19$ in der Validation. Die Einbeziehung dieser Variablen führt kaum zu einem signifikanten Informationsgewinn, da ihr Einfluss im Vergleich zur Karatzahl untergeordnet bleibt.

3.3.3 Modell 3: Vollständiges Prädiktionsmodell

Dieses Modell nutzt den maximalen Informationsgehalt des Datensatzes durch die Kombination aller metrischen Variablen mit den kategorialen Faktoren `cut`, `color` und `clarity`. Mit einem Bestimmtheitsmaß (R^2) von ca. $0,92$ erzielt es die höchste Anpassungsgüte im Training. Der $RMSE$ sinkt hierbei auf $1130,66$ (Train) bzw. $1130,54$ (Validation). Die minimale Differenz zwischen Trainings- und Validationsfehler deutet zunächst auf eine hohe Stabilität innerhalb dieser Datensegmente hin.

3.3.4 Modell 4: Domänenspezifischer Fokus (4Cs)

Modell 4 orientiert sich an der industriellen Bewertungspraxis und reduziert die Prädiktoren auf die sogenannten [2]4Cs: `carat`, `cut`, `color` und `clarity`. Es dient dazu, den Einfluss der reinen Abmessungen (`x`, `y`, `z`) zu isolieren. Mit einem $RMSE$ von $1146,88$ im Validationset erweist sich dieses Modell als fast so leistungsstark wie das Vollmodell. Bemerkenswert ist, dass Modell 4 am finalen Testset mit einem $RMSE$ von $1180,25$ den geringsten Fehlerwert aller Modelle erzielt. Dies belegt eine überlegene Generalisierungsfähigkeit für neue Daten, während Modell 3 Anzeichen von Overfitting zeigt ($RMSE$ Test: $1258,18$).

3.4 Modellvergleich und Generalisierungsfähigkeit

Trotz der hohen Güte von Modell 3 im Training zeigt der finale Test am ungesehenen Test-Set eine überlegene Performance des Modells 4, welches sich auf die domänenspezifischen 4Cs (siehe oben) konzentriert. Während Modell 3 Anzeichen von Overfitting aufweist (RMSE Test: $1258,18$), erzielt Modell 4 mit einem RMSE von $1180,25$ eine deutlich bessere Generalisierung.

Tabelle 1: Vergleich der statistischen Kennzahlen und Informationskriterien

Metrik	**Modell 1**	**Modell 2**	**Modell 3**	**Modell 4**
RMSE (Training)	1505,60	1488,48	1130,66	1159,73
RMSE (Test)	1704,63	1559,43	1258,18	**1180,25**
AIC	565258,5	564522,6	**546766,1**	548398,7

Die Modellselektion mittels des Akaike-Informationskriteriums (AIC) bestätigt zwar Modell 3 als das optimal Modell innerhalb der Trainingsdaten, die Anwendung am Test-Set priorisiert jedoch Modell 4 aufgrund seiner Robustheit gegenüber Multikollinearität.

3.5 Zusammenfassung und abschließendes Fazit

Die statistische Untersuchung des *diamonds*-Datensatzes verdeutlicht die komplexen Abhängigkeiten zwischen physischen Attributen und der Preisgestaltung auf dem Diamantenmarkt. Die explorative Analyse bestätigte die starke Rechtsschiefe der Preisverteilung sowie die dominante Rolle des Gewichts (*carat*) als primärer Preisdeterminante.

Im Bereich der induktiven Statistik lieferten die durchgeführten Tests klare Evidenz gegen eine Normalverteilung der Variable *depth*. Der gerichtete t-Test bestätigte zudem signifikante Unterschiede in den Proportionen verschiedener Schliffqualitäten, wobei *Fair*-geschnittene Diamanten im Mittel eine größere relative Tiefe aufweisen als *Ideal*-geschnittene Exemplare.

Die prädiktive Modellierung unterstrich die Relevanz der Merkmalsselektion. Während das Vollmodell (Modell 3) durch die Einbeziehung aller verfügbaren Variablen die höchste Anpassungsgüte innerhalb des Trainings- und Validationsdatensatzes erzielte, offenbarten die Ergebnisse am Test-Set eine Überlegenheit des domänenspezifischen Modells 4. Mit einem RMSE von $1180,25$ am Test-Set demonstriert dieses auf den *4Cs* basierende Modell eine höhere Robustheit und Generalisierungsfähigkeit.

Abschließend lässt sich festhalten, dass für eine präzise Preisfindung nicht die maximale Anzahl an geometrischen Messwerten entscheidend ist, sondern die Konzentration auf industriell etablierte Qualitätsstandards. Die identifizierte Multikollinearität zwischen Gewicht und Abmessungen legt nahe, dass reduzierte Modelle in der praktischen Anwendung stabilere Schätzungen liefern und weniger anfällig für *Overfitting* sind.

Literatur

[1] *ggplot2/R/data.R at v4.0.2 · tidyverse/ggplot2*. GitHub. URL: https://github.com/tidyverse/ggplot2/blob/v4.0.2/R/data.R (besucht am 15. 02. 2026).

[2] *Why the 4Cs?* GIA 4Cs. URL: https://4cs.gia.edu/en-us/4cs-of-diamond-quality/ (besucht am 16. 02. 2026).